LÍNEA DEL TIEMPO

De Deep Blue a AlphaZero

Alumna: Rico Zavaleta Astrid Paulina

Fecha de Entrega: 08 - Octubre - 2026

Análisis de la poda Alfa-Beta

1975

Knuth y Moore analizan formalmente la poda Alfa-Beta, una técnica que optimiza Minimax al descartar ramas del árbol de juego que no pueden modificar la decisión final.
Importancia: permite explorar juegos complejos con menos cálculos, sin cambiar el resultado de Minimax.

Consistencia de restricciones (AC-3)

1977

Mackworth desarrolla trabajos fundamentales sobre consistencia en redes de restricciones, base del algoritmo AC-3, que elimina valores incompatibles de los dominios de un CSP.
Importancia: reduce el espacio de búsqueda en problemas como horarios, asignación de recursos y coloreo de mapas.

Deep Blue vence a Garry Kasparov

1997

La computadora de IBM gana un encuentro de ajedrez contra el campeón mundial Garry Kasparov. Combinaba búsqueda de variantes, poda Alfa-Beta, evaluación de posiciones y hardware especializado.
Importancia: demuestra la potencia de la búsqueda adversarial y las funciones de evaluación.

Avance de la búsqueda Monte Carlo (MCTS)

2006

Kocsis y Szepesvári presentan UCT, un método que aplica principios de exploración y explotación a los árboles de búsqueda.
Importancia: MCTS permite concentrar simulaciones en jugadas prometedoras, especialmente en juegos con muchas alternativas.

AlphaGo vence a Lee Sedol

2016

AlphaGo gana cuatro de cinco partidas contra Lee Sedol. Integra redes neuronales profundas, aprendizaje y búsqueda de árbol Monte Carlo para evaluar y seleccionar jugadas.
Importancia: demuestra que el aprendizaje automático y la búsqueda pueden complementarse para resolver juegos de enorme complejidad.

AlphaZero: aprendizaje mediante autojuego

2017

DeepMind presenta AlphaZero, un sistema que aprende ajedrez, shogi y Go mediante partidas contra sí mismo. Combina aprendizaje por refuerzo, redes neuronales y MCTS, sin depender de partidas humanas como datos de entrenamiento.
Importancia: representa un avance hacia sistemas capaces de aprender estrategias generales a partir de las reglas del juego.

RESUMEN :

La evolución de la búsqueda adversarial en inteligencia artificial muestra una transición desde los métodos basados principalmente en exploración y evaluación de estados hacia sistemas que combinan búsqueda y aprendizaje automático.

Minimax permite seleccionar jugadas suponiendo que el adversario actúa de manera óptima, mientras que la poda Alfa-Beta reduce el número de ramas exploradas sin modificar la decisión. Las funciones de evaluación estiman la calidad de posiciones cuando no es posible explorar todo el árbol. Por su parte, MCTS utiliza simulaciones para orientar la búsqueda hacia acciones prometedoras.

Deep Blue (1997) destacó por la búsqueda intensiva y la evaluación especializada de posiciones de ajedrez. AlphaGo (2016) incorporó redes neuronales y búsqueda Monte Carlo para superar a un jugador profesional de élite. AlphaZero (2017) amplió este enfoque al aprender estrategias mediante autojuego en tres juegos diferentes.

Paralelamente, los problemas de satisfacción de restricciones (CSP) se desarrollaron como otra forma de búsqueda en inteligencia artificial. Técnicas como AC-3 permiten reducir los dominios de las variables antes o durante la búsqueda, facilitando aplicaciones reales como la elaboración de horarios, la asignación de recursos y la configuración de sistemas.

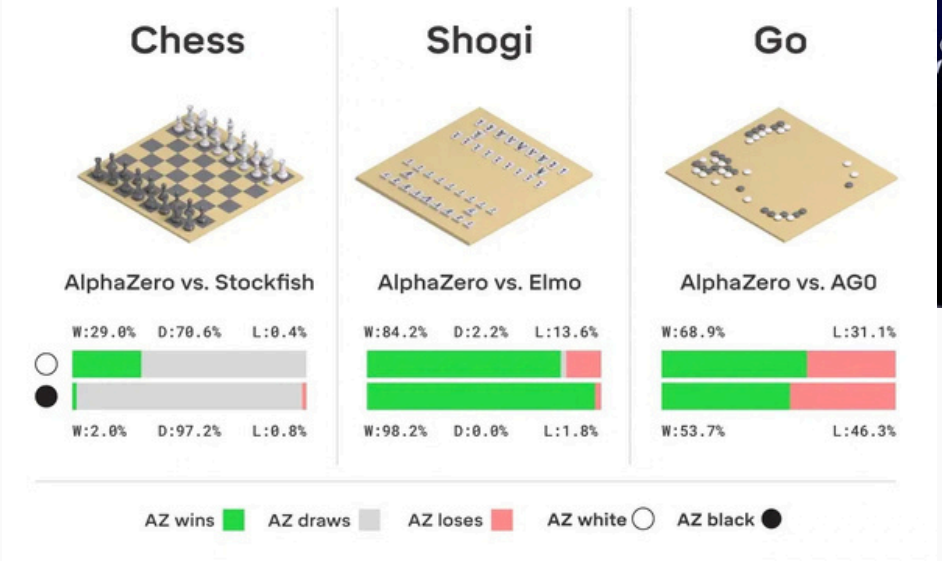
En conclusión, estos avances muestran que no existe una única estrategia de búsqueda adecuada para todos los problemas. La combinación de algoritmos, heurísticas, propagación de restricciones y aprendizaje ha permitido resolver problemas cada vez más complejos.

Tabla 1. Evolución de las técnicas de búsqueda y aprendizaje en Deep Blue, AlphaGo y AlphaZero.

Característica	Deep Blue (1997)	AlphaGo (2016)	AlphaZero (2017)
Desarrollador	IBM	Google DeepMind	Google DeepMind
Juego	Ajedrez	Go	Ajedrez, Go y shogi
Técnica principal	Búsqueda adversarial y evaluación de posiciones	Redes neuronales y MCTS	Aprendizaje por refuerzo, autojuego y MCTS
Aprendizaje	No aprendía de forma autónoma durante las partidas	Entrenamiento con partidas humanas y autojuego	Aprendizaje mediante autojuego, sin partidas humanas
Logro	Venció a Garry Kasparov	Venció a Lee Sedol por 4–1	Alcanzó un rendimiento superior al de sistemas de referencia en los tres juegos
Aportación	Demostró el poder de la búsqueda computacional especializada	Combinó aprendizaje profundo con búsqueda	Mostró un método de aprendizaje aplicable a varios juegos

Análisis comparativo: La evolución de estos sistemas muestra una transición desde la búsqueda intensiva y las funciones de evaluación diseñadas por expertos hacia modelos que aprenden estrategias mediante redes neuronales y autojuego. Deep Blue destacó por su capacidad de cálculo; AlphaGo combinó búsqueda y aprendizaje profundo; y AlphaZero amplió este enfoque a diferentes juegos mediante aprendizaje por refuerzo.







Referencias

- Campbell, M., Hoane, A. J., Jr., & Hsu, F.-h. (2002). Deep Blue. Artificial Intelligence, 134(1–2), 57–83. https://doi.org/10.1016/S0004-3702(01)00129-1
- Knuth, D. E., & Moore, R. W. (1975). An analysis of alpha-beta pruning. Artificial Intelligence, 6(4), 293–326. https://doi.org/10.1016/0004-3702(75)90019-3
- Kocsis, L., & Szepesvári, C. (2006). Bandit based Monte-Carlo planning. En Machine Learning: ECML 2006 (pp. 282–293). Springer. https://doi.org/10.1007/11871842_29
- Mackworth, A. K. (1977). Consistency in networks of relations. Artificial Intelligence, 8(1), 99–118. https://doi.org/10.1016/0004-3702(77)90007-8
- Silver, D., et al. (2016). Mastering the game of Go with deep neural networks and tree search. Nature, 529, 484–489. https://doi.org/10.1038/nature16961
- Silver, D., et al. (2018). A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play. Science, 362(6419), 1140–1144. https://doi.org/10.1126/science.aar6404