INSTITUTO TECNOLÓGICO DE TLÁHUAC III

INGENIERÍA EN CIENCIAS DE DATOS

5to semestre

INTELIGENCIA ARTIFICIAL

Tarea 5

Algoritmos bioinspirados y metaheurísticas

DOCENTE: JOSÉ ISRAEL CAMPERO DOMÍNGUEZ

Alumna : Rico Zavaleta Astrid Paulina

Num. de Control : 241120408

FECHA DE ENTREGA: Jueves 08 - Octubre - 2026

Objetivo: Analizar los principios de funcionamiento de cuatro metaheurísticas: algoritmos genéticos (GA), optimización por colonia de hormigas (ACO), optimización por enjambre de partículas (PSO) y recocido simulado (SA). Identificar sus fuentes de inspiración, operadores y parámetros, así como examinar un caso de aplicación y las implicaciones del teorema No Free Lunch.

1. Introducción

Los problemas de optimización consisten en encontrar una solución que minimice o maximice una función objetivo, respetando las restricciones establecidas. En aplicaciones como logística, planificación de horarios, diseño industrial y distribución de energía, el número de soluciones posibles puede ser tan grande que examinarlas todas resulta computacionalmente costoso.

Las metaheurísticas son estrategias generales que orientan la exploración del espacio de soluciones mediante mecanismos de búsqueda y diversificación. Algunas se inspiran en procesos biológicos o comportamientos colectivos, mientras que otras toman como referencia fenómenos físicos.

A diferencia de los algoritmos exactos, las metaheurísticas generalmente no garantizan encontrar el óptimo global en un tiempo limitado. Sin embargo, pueden producir soluciones de buena calidad con recursos computacionales razonables.

2. Principales algoritmos bioinspirados y metaheurísticas

Algoritmos genéticos (GA)

Los algoritmos genéticos se inspiran en la evolución biológica y la selección natural. Trabajan con una población de soluciones candidatas llamadas individuos, cuya calidad se determina mediante una función de aptitud.

En cada generación se seleccionan individuos para reproducirse. La cruza combina características de los padres y la mutación introduce variaciones aleatorias. Los mejores individuos tienen mayores posibilidades de transmitir sus características a las generaciones siguientes.

Operadores principales: selección, cruza, mutación, reemplazo y elitismo.

Parámetros: tamaño de población, probabilidad de cruza, probabilidad de mutación, número de generaciones y criterio de terminación.

Aplicaciones: optimización de rutas, programación de horarios, selección de características y diseño de sistemas.

Optimización por colonia de hormigas (ACO)

ACO se inspira en el comportamiento colectivo de las hormigas cuando buscan alimento. En la naturaleza, las hormigas depositan feromonas en los caminos recorridos; las rutas con mayor concentración pueden atraer a otras hormigas.

En el algoritmo, varias hormigas artificiales construyen soluciones probabilísticamente. Las rutas de buena calidad reciben refuerzo mediante feromonas, mientras que la evaporación reduce gradualmente la influencia de decisiones anteriores.

Operadores principales: construcción probabilística de soluciones, actualización de feromonas, evaporación y, en algunas variantes, búsqueda local.

Parámetros: cantidad de hormigas, importancia de la feromona (α), importancia de la información heurística (β), tasa de evaporación (ρ) y número de iteraciones.

Aplicaciones: rutas de distribución, redes de transporte, telecomunicaciones y problemas de secuenciación.

Optimización por enjambre de partículas (PSO)

PSO se inspira en el comportamiento coordinado de grupos de aves y bancos de peces. Cada partícula representa una posible solución que se desplaza por el espacio de búsqueda.

Las partículas actualizan su posición tomando en cuenta su mejor experiencia individual y la mejor solución encontrada por el enjambre o su vecindario. De esta manera, combinan exploración individual con intercambio de información colectiva.

Operadores principales: actualización de velocidad, actualización de posición y conservación de las mejores posiciones individuales y colectivas.

Parámetros: número de partículas, peso de inercia, coeficientes cognitivo y social, límites de velocidad y número de iteraciones.

Aplicaciones: ajuste de parámetros, control automático, diseño de ingeniería y optimización de sistemas energéticos.

Recocido simulado (SA)

El recocido simulado se inspira en el tratamiento térmico de materiales, mediante el cual un sólido se calienta y posteriormente se enfría de manera controlada.

El algoritmo comienza con una solución y genera modificaciones en su vecindario. Si una nueva solución es mejor, normalmente se acepta. Si es peor, todavía puede aceptarse con cierta probabilidad, lo que ayuda a escapar de óptimos locales.

En problemas de minimización, una regla habitual de aceptación de movimientos desfavorables es:

$$P = \exp(-\Delta E / T)$$

Donde ΔE representa el incremento del costo y T la temperatura actual. Conforme disminuye la temperatura, se reduce la probabilidad de aceptar soluciones peores.

Operadores principales: generación de vecinos, evaluación del cambio de costo, aceptación probabilística y enfriamiento.

Parámetros: temperatura inicial, tasa de enfriamiento, número de iteraciones por temperatura y criterio de parada.

Aplicaciones: distribución de instalaciones, diseño de circuitos, planificación de horarios y optimización combinatoria.

3. Comparación de los métodos

Los algoritmos genéticos y ACO utilizan poblaciones de soluciones, aunque sus mecanismos son distintos: GA combina y modifica individuos, mientras ACO construye soluciones mediante rastros de feromonas. PSO también utiliza múltiples soluciones, pero las actualiza mediante posiciones y velocidades. En contraste, la versión clásica de SA trabaja con una sola solución que se modifica progresivamente.

GA y ACO son especialmente adecuados para numerosos problemas combinatorios cuando se diseñan representaciones apropiadas. PSO se utiliza frecuentemente en espacios continuos. SA es flexible y puede aplicarse a problemas discretos o continuos mediante una definición adecuada del vecindario.

Ninguno de estos métodos es universalmente superior: su rendimiento depende de la estructura del problema, la representación, los parámetros y el presupuesto computacional.

4. Caso de aplicación: optimización de rutas mediante colonia de hormigas

Planteamiento

El problema del agente viajero (TSP) consiste en encontrar el recorrido de menor distancia que visite todas las ciudades una sola vez y regrese al punto inicial. Este problema tiene aplicaciones en la planificación de recorridos de reparto, inspección y transporte.

Dorigo y Gambardella (1997) estudiaron el sistema de colonia de hormigas (Ant Colony System, ACS) como método para resolver instancias del TSP. El algoritmo utiliza agentes artificiales que construyen rutas y comparten información mediante rastros de feromonas.

Metodología

Las hormigas artificiales seleccionan probabilísticamente la siguiente ciudad, considerando tanto la feromona acumulada como una medida heurística relacionada con la cercanía. Después, se actualizan las feromonas para favorecer los recorridos de mejor calidad.

Los investigadores compararon ACS con otros métodos de optimización y estudiaron variantes que incorporan búsqueda local para mejorar las soluciones.

Resultados reportados

En la instancia de referencia Oliver30, que contiene 30 ciudades, el estudio presenta para ACS una mejor distancia de **423.74 unidades** y una distancia media de **424.74 unidades**, bajo la configuración experimental correspondiente.

Estos resultados ilustran la capacidad de ACS para construir rutas competitivas mediante cooperación indirecta entre agentes. Los autores también reportaron un rendimiento favorable frente a otros métodos inspirados en la naturaleza en las condiciones estudiadas.

Es importante señalar que este caso corresponde a un experimento académico sobre rutas, no a un despliegue operativo documentado en una empresa de transporte.

Relación con la Práctica 7

En la Práctica 7 se utilizó un algoritmo genético para resolver un TSP de 15 ciudades. El algoritmo obtuvo una ruta de 313.00 unidades, mientras que una búsqueda aleatoria obtuvo 514.75 unidades con el mismo presupuesto de 30,000 evaluaciones.

Ambos trabajos muestran la utilidad de las metaheurísticas para explorar espacios de soluciones grandes. Sin embargo, las distancias de ambos experimentos no deben compararse directamente porque corresponden a diferentes conjuntos de ciudades y configuraciones.

5. Teorema No Free Lunch

El teorema *No Free Lunch* (NFL), estudiado por Wolpert y Macready (1997), establece que, bajo sus supuestos matemáticos y al promediar el rendimiento sobre todas las funciones objetivo consideradas de manera uniforme, ningún algoritmo de optimización supera sistemáticamente a todos los demás.

Esto significa que una estrategia que obtiene ventajas en determinados tipos de problemas necesariamente pierde esas ventajas en otros, cuando se considera el conjunto completo de problemas definido por el teorema.

Por ejemplo, un algoritmo genético puede obtener buenos resultados al optimizar rutas, mientras que PSO puede ser más adecuado para ciertos problemas de ajuste de parámetros continuos. Sin embargo, no es correcto afirmar que uno de estos algoritmos será siempre superior.

El teorema tampoco significa que todos los algoritmos funcionen igual en cualquier problema particular. En aplicaciones reales, es posible aprovechar información sobre la estructura del problema para seleccionar o diseñar métodos más eficaces.

Por ello, las metaheurísticas deben evaluarse mediante experimentos controlados, utilizando instancias representativas, presupuestos comparables y métricas apropiadas.

6. Conclusiones

Los algoritmos genéticos, ACO y PSO se inspiran en procesos naturales de evolución o comportamiento colectivo, mientras que el recocido simulado toma como referencia un proceso físico. Aunque sus mecanismos son diferentes, todos buscan mejorar soluciones mediante estrategias que equilibran exploración y aprovechamiento de resultados prometedores.

El caso del agente viajero muestra que los métodos metaheurísticos pueden encontrar recorridos competitivos sin examinar exhaustivamente todas las combinaciones posibles. Los resultados publicados para ACS y los obtenidos en la Práctica 7 permiten apreciar distintas formas de abordar este tipo de optimización.

Finalmente, el teorema No Free Lunch recuerda que no existe un algoritmo universalmente superior. La selección de una metaheurística debe basarse en las características del problema, los recursos disponibles y evidencia experimental.

7. Referencias

Dorigo, M., & Gambardella, L. M. (1997). Ant colony system: A cooperative learning approach to the traveling salesman problem. *IEEE Transactions on Evolutionary Computation*, 1(1), 53–66. https://doi.org/10.1109/4235.585892

Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. En *Proceedings of ICNN'95 – International Conference on Neural Networks* (Vol. 4, pp. 1942–1948). IEEE. https://doi.org/10.1109/ICNN.1995.488968

Kirkpatrick, S., Gelatt, C. D., Jr., & Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598), 671–680. https://doi.org/10.1126/science.220.4598.671

Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4th ed.). Pearson.

Wolpert, D. H., & Macready, W. G. (1997). No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1), 67–82. https://doi.org/10.1109/4235.585893